

## DEEP LEARNING

### Sistema de Predicción de futuras fallas en servidores de data centers basada en la telemetría

**Profesor:** Raul Ramos Pollan

**Estudiante:** Andrés Felipe Osorio Henker

**CC:** 98636911

#### 1. Contexto de aplicación:

La telemetría es una de las funcionalidades disponibles en los equipos de cómputo y en entornos de redes. La información suministrada por dichos equipos es recolectada y almacenada en sistemas de gestión o NMS (Network Management System) para tener herramientas de visualización de desempeño y de detección o generación de alarmas de posibles fallas en los equipos. Los datos también sirven para tener históricos con los que es posible calcular estadísticas de desempeño, disponibilidad y ANS (Acuerdos de Niveles de Servicio). Estas herramientas son por lo general reactivas y pocas veces la información suministrada por los equipos se usa para hacer análisis predictivo. Muchos de estos sistemas almacenan grandes cantidades de información de telemetría que en conjunto con las nuevas tecnologías de machine learning y deep learning se puede aprovechar para desarrollar herramientas que sirvan para mejorar la detección temprana de posibles fallas.

#### 2. Objetivo:

Predecir la fecha en la que un determinado servidor pueda fallar, teniendo como insumo la información periódica (series de tiempo) de telemetría que se tiene a disposición de los servidores de la nube Azure y de las fallas registradas en fechas dadas.

#### 3. Dataset:

El Dataset fue tomado de:

<https://www.kaggle.com/datasets/arnabbiswas1/microsoft-azure-predictive-maintenance>

De dicho Dataset se tomaron dos archivos:

- PdM\_telemetry.csv: Este es el archivo principal que contiene la información de telemetría en el tiempo de los servidores. Tiene un peso de 80.1MB.
- PdM\_failures.csv: Este archivo que tiene las fechas de las fallas de los servidores. Tiene un peso de 24.3.kB.

Los datos tienen la siguiente forma:

```
telemetry_data = pd.read_csv('/content/drive/My Drive/dataset/PdM_telemetry.csv')
print(telemetry_data.shape)
telemetry_data.head(3)
```

(876100, 6)

	datetime	machineID	volt	rotate	pressure	vibration
0	2015-01-01 06:00:00	1	176.217853	418.504078	113.077935	45.087686
1	2015-01-01 07:00:00	1	162.879223	402.747490	95.460525	43.413973
2	2015-01-01 08:00:00	1	170.989902	527.349825	75.237905	34.178847

Forma de los datos de telemetría

```
error_data = pd.read_csv('/content/drive/My Drive/dataset/PdM_failures.csv')
print(error_data.shape)
error_data.head(3)
```

(761, 3)

	datetime	machineID	failure
0	2015-01-05 06:00:00	1	comp4
1	2015-03-06 06:00:00	1	comp1
2	2015-04-20 06:00:00	1	comp2

Forma de los datos de fallas

#### 4. Métricas de desempeño:

Las métricas para medir la precisión de la predicción de una falla se dividen en métricas de precisión estadísticas y de soporte de decisiones.

**Métricas de precisión estadística:** Evaluar la precisión de una técnica de filtrado comparando las calificaciones pronosticadas directamente con la calificación real del usuario. Se van a calcular las siguientes métricas:

Error Porcentual Absoluto Medio (MAPE)

El error cuadrático medio (RMSE)

Métricas de precisión de soporte de decisiones: En esta métrica de soporte se va a medir el Accuracy que sería el porcentaje de predicciones acertadas en el tiempo correcto.

## **5. Referencias y resultados previos:**

Realizando una búsqueda en revistas científicas se ve que se ve que los modelos de Redes Neuronales Recurrentes y Long Short Term Memory son comúnmente usados para realizar la predicción del mantenimiento de equipos informáticos o industriales. Esto nos muestra que estas técnicas nos pueden servir para la solución de problema planteado en el punto 2.

También se realizó un análisis de los datos y se implementó un entrenamiento usando una red neuronal tradicional para realizar predicción de las fechas de falla de un solo servidor. Esto quedó plasmado en el notebook:

[https://github.com/aosorih/telemetry\\_servers/01\\_exploracion\\_de\\_datos.ipynb](https://github.com/aosorih/telemetry_servers/01_exploracion_de_datos.ipynb)

### **Referencias:**

A. Cachada et al., "Maintenance 4.0: Intelligent and Predictive Maintenance System Architecture," 2018 IEEE 23rd International Conference on Emerging Technologies and Factory Automation (ETFA), Turin, Italy, 2018, pp. 139-146, doi: 10.1109/ETFA.2018.8502489.

M. Vijayakumar, P. Shreeraj Nair, S. B. G Tilak Babu, K. Mahender, T. S Venkateswaran and N. L, "Intelligent Systems For Predictive Maintenance In Industrial IoT," 2023 10th IEEE Uttar Pradesh Section International Conference on Electrical, Electronics and Computer Engineering (UPCON), Gautam Buddha Nagar, India, 2023, pp. 1650-1655, doi: 10.1109/UPCON59197.2023.10434814.

Q. Wang, S. Bu and Z. He, "Achieving Predictive and Proactive Maintenance for High-Speed Railway Power Equipment With LSTM-RNN," in IEEE Transactions on Industrial Informatics, vol. 16, no. 10, pp. 6509-6517, Oct. 2020, doi: 10.1109/TII.2020.2966033.

J. S. Rahhal and D. Abualnadi, "IOT Based Predictive Maintenance Using LSTM RNN Estimator," 2020 International Conference on Electrical, Communication, and Computer Engineering (ICECCE), Istanbul, Turkey, 2020, pp. 1-5, doi: 10.1109/ICECCE49384.2020.9179459.